



UNIVERSIDAD PERUANA
CAYETANO HEREDIA


Sistema de clasificación automática de señales electrocardiográficas para la diferenciación entre pacientes sanos y patológicos mediante Machine Learning

¹ Sulca S. , ² Luque L. , ³ Callupe A. , ⁴ Borda E., ⁵ Llanos M.

¹ Universidaad Peruana Cayetano Heredia (UPCH)

Introducción

Las enfermedades del corazón son la principal causa de muerte en el mundo, con cerca de 19,8 millones de víctimas al año [1].



La herramienta para diagnosticarlas es el electrocardiograma (ECG), que registra más de 300 millones de pruebas al año en todo el planeta [2].

Problemática

La interpretación de ECGs enfrenta una severa escasez de cardiólogos, con apenas 42 especialistas por cada 100 mil habitantes en Perú, lo que genera cuellos de botella en la atención primaria [3]. La se agrava debido a que los médicos generales suelen sentir que su formación de pregrado es insuficiente para detectar anomalías [4]. Adicionalmente, hay una gran dificultad técnica, ya que la interpretación visual es obstaculizada por ruidos en los registros crudos como la interferencia de red, la deriva de la línea base y el ruido muscular que deforman parámetros clínicos vitales y reducen drásticamente la precisión diagnóstica [4].


Propuesta de solución

Se propone el desarrollo de un sistema ágil basado en Machine Learning para la clasificación binaria automática (Sano vs. Patológico) operando sobre archivos digitales crudos. El sistema analiza paramétricamente solo las tres derivaciones frontales (I, II y III). Este proceso integra un acondicionamiento por filtrado de fase cero, seguido de la extracción de características predictivas clave como la Energía Efectiva (RMS), la Varianza y la Frecuencia Cardíaca. Finalmente, este modelo se mostrara en una interfaz gráfica interactiva equipada con alertas cromáticas, diseñada para optimizar el triaje médico descentralizado.

Metodología

1 Adquisición de Datos


Database(PhysioNet): Extracción de señales de la base clínica PTB Diagnostic ECG Database fs= 1kHz señal=mV



Separación de Pacientes: Entre sujetos con patologías y pacientes sanos). Se recolectaron 290 muestras



Hardware de Validación: Placa BITalino, operando a 1kHz con un ADC de 10 bits y 3 derivaciones (I,II,III).




2 Preprocesamiento de datos


Calibración física: Valores discretos crudos → mV mediante una función proviente de la base

$$ECG(mv) = \frac{(\frac{ADC}{1023} - 0.5) \times 3.3}{1100} \times 1000$$


Filtro Notch (50Hz): Interferencia eléctrica, frecuencia en Alemania



Filtro Butterworth (0.5 - 45Hz): Respuesta plana en su banda de paso




Filtro bidireccional : Filtrado de fase cero para no deformar el complejo QRS y no haya retraso



3 Extracción de características

Extracción temporal y morfológica: BPM, ancho QRS,



Extracción energética: RMS, varianza de las tres derivaciones


ID_Paciente	Pres_Cardíaca	RMS_I	RMS_II	RMS_III	Var_I	Var_II	Var_III	Ancho_QRS_ms	Efectiva
patient05	60.01097207	0.230254263	0.20192546	0.277508364	0.0231003035	0.0680540439	0.0000027271	188.3622174	0
patient04	62.82728513	0.139880178	0.136288145	0.037888032	0.0186882853	0.0184848522	0.0014241306	84.776	0
patient21	78.32058913	0.130640185	0.120791228	0.105860393	0.0178823202	0.040107842	0.0247070504	186.1776316	0
patient10	67.1548695	0.170544327	0.201364292	0.147389188	0.0014558131	0.0469392446	0.0215891818	87.1711171	0
patient14	96.13131144	0.116802046	0.152897809	0.113588414	0.0138056689	0.0233185261	0.0128871506	85.4744886	0
patient04	77.78937288	0.0643882012	0.100314463	0.1003114463	0.00446577892	0.0225854045	0.0117913871	84.3087142	0
patient04	88.34324142	0.1451859355	0.0693898985	0.1058445313	0.02106183595	0.009871373	0.0111007468	95.07370158	0

4 Arquitectura IA

Acondicionamiento matemático: Normalización z-score


SMOTE: Balanceo de clases mediante la generación de pacientes sintéticos

Clasificador: Generación de un modelo predictivo usando Random Forest




Resultados

Gran desbalance y necesidad de Smote para balancear



La distribución de frecuencia cardíaca mostró una diferencia notable entre los picos



Precisión (macro) **0.79**

Recall (macro) **0.85**


F1-Score (macro) **0.81**

Se descargó directamente de PhysioNet un registro adicional de un paciente sano, y luego se procedio a filtrarlo mediante la pagina web



87.93%


EXACTITUD GLOBAL



Interfaz Web



Finalmente desarrollamos una pagina Web, mediante Steam, para la visualizacion y procesamiento de las señales que se ingresent (.Hea o txt)



Conclusiones

- Con solo 3 derivaciones frontales y 8 características se logró clasificar ECG en sano/patológico con 87.93% de exactitud en un conjunto de prueba reducido.
- La mejora principal provino de incorporar el ancho del QRS (77.59% → 87.93%); SMOTE no aumentó la exactitud, pero redujo el sesgo hacia la clase patológica.
- La prueba con BITalino y un control externo funcionó como prueba de concepto.

Limitaciones: pocos registros sanos y validación física con limitada población
Mejoras futuras: ampliar la cohorte sana, comparar con otros clasificadores y validar en más sujetos de prueba.

Bibliografía

- [1] [1] World Health Organization: WHO, "Enfermedades cardiovasculares," Jul. 31, 2025. <https://www.who.int/es/news-room/fact-sheets/detail/cardiovascular-diseases-cvds>.
- [2] Holst, H., Ohlsson, M., Peterson, C. y Edenbrandt, L. Un sistema confiable de apoyo a la toma de decisiones para la interpretación de electrocardiogramas.Fisiología Clínica.19, 410–418 (1999).
- [3] A. B. Reisman, "El Perú tiene apenas 42 médicos especialistas por cada 100 mil habitantes," El Comercio Perú, Jun. 18, 2024. <https://elcomercio.pe/ecdata/el-peru-tiene-apenas-42-medicos-especialistas-por-cada-100-mil-habitantes-minsa-regiones-ecdata-noticia/?ref=ecr>
- [4] R. C. Puerta and E. L. Martinez, "La habilidad de interpretar el electrocardiograma desde una perspectiva moderna," Dialnet, 2025. <https://dialnet.unirioja.es/servlet/articulo?codigo=10402536>
- [5] C.-S. Lin, W.-T. Liu, Y.-H. Chen, S.-H. Lin, and C. Lin, "Artificial intelligence-enabled electrocardiography from scientific research to clinical application," EMBO Molecular Medicine, vol. 18, no. 1, pp. 22–40, Dec. 2025, doi: 10.1038/s44321-025-00351-y.
- [6] M. Nakayama, R. Yagi, and S. Goto, "Deep learning applications in 12-lead electrocardiogram and echocardiogram," JMA Journal, vol. 8, no. 1, pp. 102–112, Jan. 2025, doi: 10.31662/jmaj.2024-0195.